AI 因子挖掘，为什么依然跑不赢十年前的 Alpha101?

QuantML QuantML 2026年10月8日 07:30 上海

伦敦国王学院的研究团队提出了包含五大股票市场与约五千个生成因子的统一基准 FactorBench，系统检验了遗传编程、强化学习、生成模型和大语言模型智能体这四类自动化因子挖掘方法在样本外组合中的实际价值。

论文题目：FACTORBENCH: A PORTFOLIO-AWARE BENCHMARK FOR AUTOMATED FACTOR MINING
作者：Zhuohan Wang, Carmine Ventre
机构：伦敦国王学院信息学系（Department of Informatics, King's College London）

从早期的符号遗传编程，到强化学习与语法引导的表达式搜索，再到近期的扩散生成模型与多智能体系统，文献中报告的样本内指标不断攀升。然而，这些纸面指标进入组合构建阶段时经常出现偏差：样本内的高 IC 在样本外迅速衰减；同一套搜索流程产出的数百个候选公式往往高度共线；由其合成的复合信号在扣除风格暴露与交易摩擦后，其增量表现甚至难以匹敌十年前公开的经典基准。更关键的是，不同算法通常在异构的数据清洗规则、股票池定义以及调仓假设下各自汇报结果，缺乏标准化的横向评估环境。

这篇论文主要讨论当前主流的自动化因子挖掘算法到底能不能产出真正具备组合价值的有效信号，以及这种方法为什么能够成立。 来自伦敦国王学院的团队做了一项大规模横向评测，他们搭建了一个统一的评估环境 FactorBench，把过去近十年代表性的九种挖掘方法拉到同一基准线上。测试覆盖了美股标普100、港股恒生指数、A股沪深300、英股富时100以及日股日经225五个主流市场，累计评估了接近五千个挖掘因子。评测没有停留在单因子的统计指标上，而是完整追踪了从代码有效性、风格剥离、因子池内部冗余，一直到扣除交易成本后的投资组合表现。实验结果给出了一个明确的结论，从早期的符号进化到如今的大模型智能体，并没有哪种方法展现出全方位的优势，许多看似更先进的模型，实际收益仅仅是把市场上已知的风险风格重新包装了一遍。

核心观点

1. **复杂算法没有系统性占优。** 从遗传编程到强化学习与大模型智能体，没有哪种技术路线能在所有维度上保持领先。大模型在编写代码时表现得更自由，但在跨市场和跨周期的严苛测试里，它构建出的组合并不比传统符号搜索更稳健。
2. **训练期的高指标多半来自过拟合。** 强化学习与遗传算法在训练集上反复寻优，很容易把固定的历史规律拟合到极致，结果一进入验证和测试阶段就大幅衰减。大模型智能体在样本外的降幅看起来相对平缓，但这主要是因为它在样本内原本就没有进行深度的参数优化，并不是泛化能力有多么突出。
3. **海量因子大多只是重现已知风格。** 当研究团队对因子剥离掉市场贝塔、波动率、动量、短期反转和流动性五大常见风险后，绝大多数算法的残差 IC 出现了断崖式下跌。遗传编程是在基础量价里无意识拼出反转或动量，大语言模型则受制于训练语料的先验，频繁写出文献里早已公开的经典均线和突破逻辑。

4. **因子池膨胀掩盖了内部严重同质化。** 单次挖掘产出一两千个公式并不代表捕捉到了丰富的信息。各家算法生成的因子池内部相关性普遍偏高，而且大模型智能体产出的因子不仅彼此高度相似，还大面积撞车十年前公开的经典 Alpha101 公式。
5. **多头繁荣遮掩了多空两端的缩水。** 在纯多头测试中，由于测试期主要指数整体向上漂移，加上等权配置本身的分散效果，几乎所有算法都能取得 20% 以上的年化净收益。但一旦构建严格对冲市场波动的美元中性多空组合，多数算法的收益便被急剧压缩，部分大模型算法在扣除千分之一交易成本和融券利息后甚至录得负夏普比率。

从符号回归到大模型智能体

要理解这项评测的价值，首先得看自动化因子挖掘在评估上的断层。过去这十年里，因子挖掘的探索换了好几套工具。最早是基于遗传编程的符号回归，通过算子树的交叉突变来搜索公式。后来强化学习和上下文无关文法成为主流，像 AlphaGen、AlphaQCM 和 AlphaCFG 会用策略网络引导表达式生成。再到近两年，AlphaForge 等生成式方法开始用扩散模型批量采样公式，而 R&D-Agent、AlphaAgent 等大模型系统更是直接让智能体阅读研报来编写复杂的计算代码。

工具更迭非常迅速，但学术界过去的评测环境却各自为战。不同研究选取的资产池、调仓节奏和去极值规则各不相同，算法优化时往往也把全部精力押在训练集 IC 这类单一指标上。在噪声极大的金融时间序列里，对单一指标过度拟合，换来的往往只是样本内的虚假繁荣。

FactorBench 的核心做法就是把这些算法放到完全相同的考场里。研究团队统一采用标普100、恒生指数、沪深300、富时100和日经225五个主流市场，输入统一的开高低收和成交量基础量价，预测目标固定为未来 20 个交易日的区间收益。时间切分也十分明确，2017 至 2021 年留给算法在训练集上自由挖掘，2022 至 2023 年作为特征筛选与超参调优的验证期，2024 至 2025 年则是完全隔离的样本外测试期。

为了能横向对比不同形态的算法，基准在工程上打通了一套双轨执行契约。遗传算法和强化学习输出的是符号表达式语法树，而大模型智能体交付的是原生 Python 函数。评测系统将这两类异构输出统一映射为标准的日期资产截面矩阵，让所有算法在相同口径下接受检验。各方法的计算开销因此显现出巨大悬殊，基础的遗传编程跑一次只要 0.14 小时，AlphaSAGE 也仅需 0.31 小时，但 AlphaQCM 增长到了 8.19 小时，R&D-Agent 耗时 10.77 小时，QuantaAlpha 更是达到了 27.9 小时。计算开销拉开了近两百倍的差距，然而多花出的算力并没有自然换来更高质量的信号。

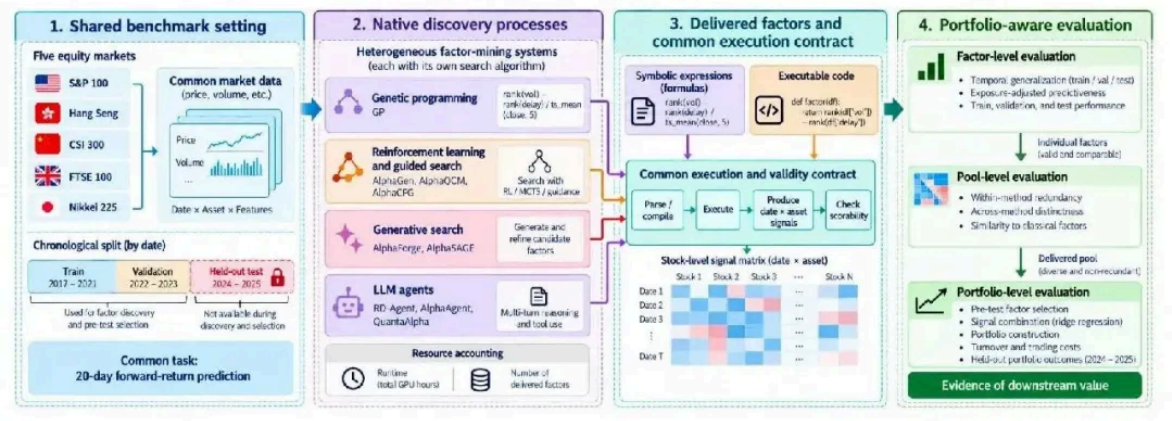


Figure 1: Overview of FactorBench.

公众号 · QuantML

单因子有效性与已知风格剥离

代码能否正常执行是因子落地的第一道门槛，而这一步就直接暴露出了不同范式的工程差距。基于固定算子集生成的符号表达式，因为语法树受到严格约束，在各个市场上的可执行率和可打分率基本都在 95% 以上，遗传编程甚至保持在 100%。但直接让大模型编写 Python 代码时，代码的脆弱性便暴露无遗。以 R&D-Agent 为例，其实际可运行率只有 82.2%，能够计算截面有效值的可打分率进一步降到了 81.3%，AlphaAgent 的可打分率也仅有 80.5%。语法报错、未捕获的空值传播以及输出方差为零等状况频频出现。大模型在编写灵活逻辑上看似自由，但在缺乏严格语法检验时，交付有效代码的稳定性明显不如传统的符号搜索。

Table 1: Resource usage and factor validity.

Method	Hours/Run	Delivered	Executable count (%)	Scorable count (%)
Alpha101	–	71	71 (100.0%)	70 (98.6%)
GP	0.14	300	300 (100.0%)	300 (100.0%)
AlphaGen	1.66	150	150 (100.0%)	149 (99.3%)
AlphaCFG	2.37	150	150 (100.0%)	139 (92.7%)
AlphaQCM	8.19	143	143 (100.0%)	142 (99.3%)
AlphaForge	1.29	1,572	1,572 (100.0%)	1,535 (97.6%)
AlphaSAGE	0.31	750	750 (100.0%)	696 (92.8%)
R&D-Agent	10.77	107	88 (82.2%)	87 (81.3%)
AlphaAgent	5.08	123	99 (80.5%)	99 (80.5%)
QuantaAlpha	27.90	1,619	1,586 (98.0%)	1,551 (95.8%)

公众号 · QuantML

随后的跨期测试揭示了训练期指标的局限性。传统的遗传编程、强化学习和扩散模型在训练集上都能拿到极高的 IC，可是一旦进入验证期便快速滑落，在测试期表现进一步收窄。大模型智能体从训练到测试的数值降幅看起来相对温和，表现出更平缓的曲线。

如果仅看衰减幅度，很容易得出大模型更稳健的表面结论，但这其实忽略了初始水平的差异。大模型在训练期拿到的 IC 本身就偏低，它的降幅较小是因为缺乏高强度的参数拟合，并不是它的样本外泛化能力有质的飞跃。传统的强化学习和遗传算法是在固定窗口里密集搜寻极值，把样本内的规律榨取殆尽，大模型智能体则主要通过多轮交互提出修改建议。进入样本外测试期后，大模型产出因子的绝对预测力并没有实质性胜过传统方法。

更严峻的考验来自于风格剥离。在多因子体系里，如果一个信号的预测力主要依靠承担已知风险，它并不能为投资组合带来真正的特异性超额。研究团队将所有因子在截面上对市场贝塔、波动率、动量、短期反转和流动性五大经典风格做了回归，并观察剥离后的残差 IC。

回归结果呈现出普遍的缩水趋势。绝大多数因子在剔除常见风格后预测力大打折扣，遗传编程、AlphaForge 和 AlphaGen 剔除风格后的残差 IC 出现了大面积下滑，在多个市场甚至直接转为负值。R&D-Agent 的复合原始 IC 达到了 0.0253，在全场所有方法中位列第一，但剥离五大风格后残差 IC 骤降到了 0.0011。

这种现象的成因其实很清晰。传统的遗传编程通过基础量价的代数运算与时序平滑，在穷举过程中极易重新构造出已知的量价特征组合。大语言模型在预训练时读过了太多的金融论文与行业研报，在代码生成时天然偏好均线交叉、通道破位等经典技术分析模式。两者机制不同，但最终都不约而同地落入对已知风险风格的重新描摹之中。

因子池的内部同质化与对经典文献的再现

当单个因子难以维持稳定预测时，部分系统转向了批量生成的策略，单次产出上千个候选因子。例如 AlphaForge 单次交付 1572 个因子，QuantaAlpha 交付 1619 个因子。然而，名义上的因子数量并不等同于增量信息的丰富程度。

研究团队通过计算因子池内部的横截面斯皮尔曼秩相关系数，对生成结果的多样性进行了评估。实验表明，AlphaGen 与 AlphaQCM 内部的因子重复度极高，因子间的相似度中位数长期维持在高位，表明其搜索过程主要在狭窄的局部空间内做参数微调。

生成式方法 AlphaSAGE 的表现则高度依赖市场，在沪深300上产出的因子高度同质，在其他市场才稍微散开。显然，生成大量公式并不等于提供了丰富的信息，多数时候只是相同逻辑在参数上的微调与重组。

在跨算法的比较中，因子池呈现出极为鲜明的门派聚集效应。非大模型的符号搜索方法往往彼此相似，其中同属于强化学习路线的 AlphaGen 与 AlphaQCM 重合度最高，这与它们共享相近的符号空间与强化学习环境密切相关。而三款大模型智能体产出的因子池则高度聚类在一起，与其他传统方法的交集明显偏少。这很有意思，因为大模型智能体虽然由不同团队开发，但由于都使用了主流的商业大模型基座，内化了相同的金融语言先验，无论提示词怎么调整，它们脑海里的投资逻辑都大同小异。

更具启发性的发现来自与经典基准 Alpha101 的比对。研究团队选取了无需行业分类即可严格落地的 71 个经典 Alpha101 因子作为外部参照。对比结果显示，三款大模型智能体生成的因子池与 Alpha101 的相似度显著高于传统符号挖掘方法，其中 R&D-Agent 的重合度最为突出。

这种重合源于生成机制的内在倾向。大语言模型倾向于输出符合金融经济学直觉的代码片段，而这些直觉在很大程度上早已被经典研究所形式化。它在已知经验空间的表述重组上表现熟练，但受制于语言先验的约束，难以触及那些脱离常规直觉却具备统计特异性的新空间。

投资组合构建与扣除交易摩擦后的实际表现

把成百上千个挖掘出的公式装进真实的交易账户，中间经历的信息损耗往往比预期严重得多。

FactorBench 在组合层面的处理非常克制。算法交付的因子池先在样本内做截面相关性筛除，去掉彼此雷同的冗余项，剩下的因子通过岭回归学习配置权重，并在验证集上确定正则化强度。为了贴合机构调仓的真实摩擦，回测统一执行 20 个交易日的调仓周期，每笔买卖扣除单边万分之十的交易成本，多空组合还要额外计入融券借贷费用。

如果只看纯多头组合的净值，几乎所有算法的数据都非常漂亮。各家扣除费率后的年化复合收益普遍落在 22.4% 到 31.2% 的区间，夏普比率也都在 1 以上。其中 R&D-Agent 跑出了 31.2% 的年化净收益，AlphaQCM 的夏普比率达到了 1.313。

但这主要反映了外部市场环境的顺风。2024 到 2025 年的样本外测试区间内，全球主要权益市场整体处于震荡走强阶段，纯多头组合天然吸收了大量的市场贝塔。再加上基准本身是全成分股等权配置，小市值股票的弹性进一步推高了多头净值。如果脱离对冲环境，这种单向做多的收益很容易让人对算法的真实选股能力产生误判。

真正的分水岭出现在美元中性的多空组合里。

多空对冲抹平了指数层面的整体涨跌，各个挖掘算法的收益空间随即出现断崖式收缩。此时方法之间的底层差距彻底暴露出来。表现最好的 R&D-Agent 和 AlphaQCM 在多空两端分别拿到了 0.679 和 0.668 的夏普比率，但两者赚钱的机制完全不同。

R&D-Agent 的年化换手率高达 7.8 倍，调仓磨损极为沉重。更为关键的是它的残差 IC 在剔除五类常见风格后直接缩水到了 0.0011。这表明 R&D-Agent 在多空两端拿到的超额，主要由未中性化的宏观风格暴露驱动，微观个股层面的特异性阿尔法其实微乎其微。

AlphaQCM 的收益来源则干净得多。它在测试期维持了全场最低的 4.6 倍年化换手率，其残差 IC 在中性化处理后依然保留了 0.0175，相比原始 IC 的 0.0191 几乎没有折损。这说明该算法确实提炼出了与经典量价风格相对正交的信息增量。相比之下，AlphaAgent 在扣除交易摩擦与借券费用后，多空夏普比率直接转为了负值 -0.087。

更耐人寻味的是横截面单调性。大部分挖掘算法合成后的信号，其横截面秩相关系数 RankIC 普遍很小，遗传算法和多个强化学习方法甚至录得了负的 RankIC。这意味着它们给股票排出的相对顺序在样本外并不具备稳定的单调预测力。反观十年前公开的经典 Alpha101，71 个无行业标签的公式在测试期拿到了 0.0176 的 RankIC，位列全场第一。在剥离五大风格后，Alpha101 的残差 IC 稳稳停在 0.0237，多空夏普比率达到 0.319。在漫长的技术演进之后，多数耗费大量算力挖掘出的复合信号，在严谨的中性化检验下依然很难超越这些经典的公开配方。

当然，FactorBench 当前的组合设计也有明确的前提假设。统一基准采用了静态的成分股列表，真实交易中指数成分调整带来的动态剔除与幸存者偏差未被完整还原。回测假设了线性的交易成本与理想借券条件，尚未纳入非线性冲击成本函数与大资金容量约束。风格剥离目前也受限于公开数据字段，只覆盖了流动性和波动率等量价暴露，还没有推进到细分行业中性化。

这些未被完全覆盖的边界，恰恰构成了检验量化因子的实际硬指标。在评估一套挖掘系统时，比起在训练集里堆砌复杂的计算图或追求好看的纸面 IC，更需要观察的是信号在经历去相关与风格剥离后能否留下真正的净残差，以及这些微弱的截面优势在承受现实换手与借贷成本磨损后，还能否转化成正向的组合信息比率。

关于QuantML

QuantML 是链接全球顶尖量化人才的高端社群，我们聚焦于机器学习在量化投资中的最前沿应用。

核心价值：

- **顶级社群：** 社区涵盖头部机构从业者、知名私募创始人、机构量化负责人，基金经理，券商金工分析师、GitHub千星作者及顶会学者构成。

- **专业研究：** 持续分享前沿论文、论文研报复现、模型代码、核心Alpha因子以及QuantML-Qlib框架等。

论文 · 目录

上一篇
情绪指标的非对称陷阱：来自百万新闻的证据

下一篇
传统因子与深度学习如何结合？基于LeCun世界模型JEPA的预测框架

作者提示: 个人观点，仅供参考