传统因子与深度学习如何结合？基于LeCun世界模型JEPA的预测框架

QuantML QuantML 2026年10月12日 16:30 上海

针对股票市场截面预测中信噪比极低与传统端到端深度网络容易过拟合的问题，香港科技大学与上海交通大学联合团队提出了 STOCK-JEPA 架构，将经典线性定价先验作为潜空间锚点，引导神经网络专门学习可预测的增量位移。

论文题目：STOCK-JEPA: Prior-Anchored Latent Revision Representation Learning in Equity Markets
论文作者：Yizhi Luo, Jiahe Yi, Jianhui Zhang, Shuo Sun
作者机构：香港科技大学（广州）、上海交通大学、北京中关村实验室

在量化资产定价领域，利用深度学习挖掘超额收益一直面临着信噪比瓶颈。股票资产在未来真实时间窗口内的价格变化，包含大量在预测时点尚未公开的新增信息与不可预测的随机扰动；若直接采用深层网络端到端拟合已实现收益率，模型很容易陷入对样本内特定噪声的过度拟合，从而导致样本外泛化能力急剧衰减。另一方面，以 Fama-MacBeth 回归或条件因子模型 IPCA 为代表的经典金融学工具，虽然具备清晰的经济学结构与截面稳健性，但其受限于严格的线性形式假设，难以刻画资产特征与宏观状态之间的高阶非线性交互。过往将两者结合的残差学习方法，多在收益率空间直接建模未解释残差，但实际观测到的残差往往混合了遗漏的有效信号与纯粹的随机噪音，难以有效解耦。

这篇论文主要讨论如何将低复杂度金融模型生成的时点先验映射为潜空间基准锚点，驱动联合嵌入预测网络仅针对该锚点预测可预测的增量修正，并给出了这一机制在信息论与泛函投影上的严格保证。 研究团队将联合嵌入预测架构引入股票市场建模，改变了以往直接重构观测序列或无约束预测未来潜变量的做法。系统首先利用滚动扩展窗口下的多输出岭回归模型生成覆盖多周期收益、波动与回撤的低维先验统计量，并通过映射网络将其投影至目标潜空间构建基准锚点；随后利用时序编码器与增量预测器，基于历史量价序列估计未来状态相对于该锚点的可预测位移，并通过双分支独立损失函数与梯度截断阻断两者的参数补偿。在覆盖中美全市场股票池的长周期时序测试中，该模型在完全冻结表征的评估协议下，截面排序能力、净夏普比率以及最大回撤控制均显著优于现有主流时序网络与传统因子基线。

核心观点

1. **先验作为基准锚点。** 深度网络无需承担从零拟合全部市场规律的负担，通过引入低复杂度线性模型对多周期收益与风险指标的先验估计，可在高维潜空间确立稳定的坐标原点；该设计守住了传统资产定价理论的结构底线，使深度学习能够专注于挖掘非线性增量信息。
2. **在表征空间对齐目标。** 资产未来的实现收益混杂着大量事前不可获知的随机冲击，直接端到端拟合原始标量极易导致过拟合；联合嵌入预测架构在抽象特征空间对齐未来状态的综合表征，能够主动滤除微观路径中的不可预测噪音。
3. **解耦优化避免两分支相互代偿。** 先验映射器与修正网络各自拥有独立的损失函数。修正预测器在读取锚点特征时被显式阻断反向传播，这样可以避免高参数量的上下文网络单方面吸收先验误差，维持锚点原本的资产定价基准含义。

4. **条件投影确定误差的理论下限。** 在均方误差准则下，历史序列对先验锚点的修正可视为大信息流对小信息流的正交投影。理论证明，最优修正带来的均方误差降幅恰好等于该增量信号自身的期望平方模长；一旦历史信息缺乏增量价值，修正值便在概率意义下收敛到零，保证预测风险不会劣于单纯先验。

截面收益预测中的信噪比与过拟合

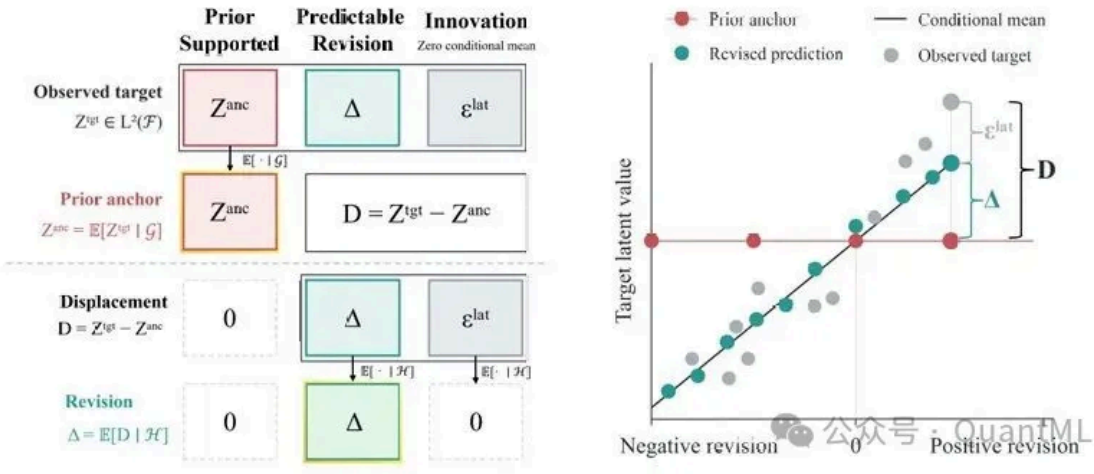
将深层神经网络直接用于股票截面收益预测，最容易遇到的问题是模型对样本内微观路径的过度拟合。

核心原因在于金融数据极低的信噪比。资产价格的未来实现值不仅由当前可观测信息驱动，更由未来时间窗口内随机释放的各类事件所决定。端到端训练直接将包含不可预测冲击的已实现收益作为监督目标，迫使参数量庞大的神经网络在低信噪比样本中强行拟合微观波动。这种拟合本质上是在记忆样本特定的偶然噪声。其结果往往是样本内均方误差持续下降，而样本外的截面排序能力和多头组合收益迅速失效。

与此形成鲜明对照的是经典实证资产定价模型。无论是以特征作为工具变量的条件因子模型 IPCA，还是经典的截面回归，都坚持采用低维、受约束的线性结构。这类模型虽然无法拟合复杂的非线性形态，却拥有明确的经济学基准和极强的样本外鲁棒性。

调和这种矛盾的传统思路是残差学习。研究者通常先用经典因子模型拟合基准收益，再用机器学习模型去挖掘残差中的 Alpha 信号。然而，这种在收益率空间直接分离残差的做法存在明显的理论缺陷。

直接观测到的残差并非纯净的有效信号，而是模型遗漏的非线性信息与不可预测市场噪音的叠加态。当深层网络以标量残差为学习目标时，它依然无法判断眼前的数据究竟是可预测的模式还是纯粹的随机漫步。这就导致残差层面的二次挖掘依然深陷噪声拟合的泥潭。



潜空间锚定与条件增量修正

STOCK-JEPA 解决这一问题的切入点，在于放弃在原始标量空间直接做残差分解，转而在自监督学习的潜表征空间中实现先验与增量的分离。

该方法借鉴了联合嵌入预测架构的核心哲学。在计算机视觉和自监督时间序列中，JEPA 架构通过预测未来上下文在潜空间的嵌入表征来学习系统动态，避免了生成式模型逐像素或逐时间点重构原始输入的

繁重开销。将其迁移到金融领域具有天然的适应性：量化投资并不需要精确预测未来每一个交易日的具体收盘价，只要能够准确把握资产未来状态在收益预期、波动特征与回撤风险上的综合表征即可。

然而，通用的 JEPA 无法直接套用于股票截面。通用架构将全部输入统一视为无差别的时序特征，既没有考虑经典资产定价理论积累的结构性认知，也无法在数学上区分哪些是已有先验即可解释的部分，哪些是历史上下文带来的增量预测价值。

为了解决这一问题，研究团队在潜空间内部构建了一个由时点先验所支撑的基准锚点。

在预测时点，系统首先输入涵盖个股量价、波动、流动性以及市场宏观特征的 40 维描述符，利用一个参数固定的多输出岭回归模型，分别预测未来 5 个交易日与 21 个交易日的四组关键统计量：累计对数收益、未年化波动率、最大对数回撤，以及相对等权市场的超额收益。这八项预测值连同它们在滚动拟合周期内的历史残差尺度，共同构成了 16 维的结构化先验向量。

这一先验向量由低复杂度模型严格按时序扩展窗口生成，在后续的表征学习阶段保持固定。

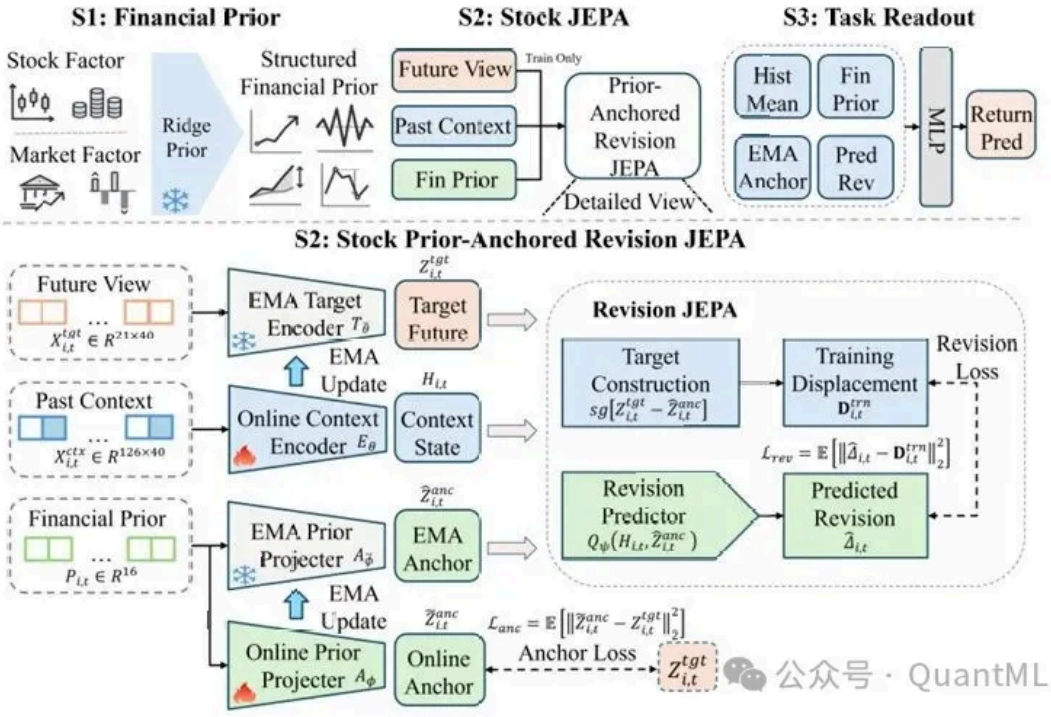
随后，一个多层感知机先验映射器将这 16 维统计量投射到 128 维的目标潜空间中，生成基准锚点。与此同时，未来的真实 21 天多变量行情窗口被目标编码器映射为对应的真实目标表征。基准锚点的目标极其明确：在目标编码器确立的潜空间内，仅凭经典低复杂度先验，对未来的真实状态做出最佳的无偏估计。

在基准锚点确立之后，历史上下文编码器处理过去 126 个交易日的时序输入，并由增量预测器接收上下文表征与该锚点，专门估计真实目标表征偏离锚点的相对位移。

从泛函分析的角度来看，这一机制具备严格的理论保证。若将先验统计量与包含历史上下文的全部特征分别定义为递增的两个信息流，则在平方可积空间内，对未来真实表征的条件期望本质上等同于正交投影。

论文中的数学推导证明了一个关键结论：利用更丰富的历史信息去修正先验锚点时，最优修正能够带来的预测平方风险降幅，严格等于该增量修正信号的期望模长平方。若历史序列无法提供超出先验的增量预测价值，最优修正便在均方意义下恒等于零，系统自然回退至先验基准。

这意味着引入历史时序进行表征修正，在统计意义上能够确保预测性能下限不低于传统先验模型，从理论层面规避了深度学习因盲目过拟合而跑输简单基准的常见缺陷。



双分支解耦与梯度阻断机制

将潜空间表征拆解为先验锚点与增量修正之后，模型在工程实现上必须解决参数优化的解耦问题。

如果将先验映射输出与增量预测输出简单相加，并使用单一的复合均方误差直接拟合未来目标，优化器往往会选择阻力最小的参数更新路径。修正分支拥有更深的 Transformer 层数与更强的非线性表达能力，在没有约束的情况下，极易自发代偿先验分支的工作；反之，先验映射器也可能为了顺应复合损失而产生剧烈形变，最终丧失作为稳健金融基准的功能。

为了防止两分支出现不期望的相互代偿，STOCK-JEPA 实施了完全分离的双分支优化路径。

首先是损失函数的独立划分。先验映射器拥有独立的锚点损失函数，其目标仅仅是让投射后的先验尽可能接近未来的目标表征。该分支反向传播计算出的梯度，严格局限在先验映射器内部，不参与任何上下文时序参数的更新。

其次是增量修正分支的梯度阻断。在计算增量预测器的输入以及真实的潜位移监督标签时，输入系统的基准锚点均被施加了停止梯度操作。增量预测分支只能将基准锚点作为固定的环境常量来读取，其预测位移产生的损失函数完全用于更新上下文 Transformer 编码器与修正网络。

此外，为确保训练目标的平稳性，系统在潜空间构建中全面采用了指数移动平均更新机制。目标编码器以及提供推断锚点的先验映射器均通过对应的在线网络以高衰减率平滑更新，且在反向传播中不接收任何梯度。

针对金融潜变量在训练初期数值波动剧烈的问题，算法在修正分支引入了动态一阶与二阶统计量追踪，对位移目标执行逐坐标归一化与截断约束，迫使网络仅在标准化坐标系下预测平稳的相对位移，下游输出时再通过逆变换还原。

这种分工机制确保了系统各司其职：先验分支专注于捕捉跨周期的稳态结构，修正分支则全力从历史序列中提炼出真实的动态位移。

全市场回测检验与尾部风险控制

为了检验冻结表征在实际投资组合中的有效性，研究团队在中美全市场股票池上进行了严格的时序实证检验。

评估表征质量时，第二阶段训练好的编码器和映射模块在下游全部冻结。下游仅使用两层MLP来预测未来 21 个交易日收益，输入包含 40 维历史均值、16 维原始先验、128 维锚点以及 128 维预测修正，合计 312 维特征。不进行端到端微调，直接观察这组固定表征能否为线性或浅层回归提供足够的截面区分度。

样本涵盖了 Wind 5669 只 A 股 与 Norgate Data 10152 只美股数据，退市样本均保留在内。回测区间为 2024 年 1 月至 2026 年 6 月，特征缩放与第一阶段岭回归均采用按年递增的滚动时序窗口。交易假设相对贴近实际：以信号发出次日的开盘价买入并持有 21 个交易日，扣除单边万分之五的手续费。A 股构建 30 只个股的等权多头，美股则构建前 30 多头与后 30 空头的对冲组合。

在这套统一约束下，STOCK-JEPA 在 A 股全市场实现了 11.22% 的平均 RankIC，明显高于 MASTER 的 9.84%、IPCA 的 8.69% 与 FactorVAE 的 6.20%。扣费后年化净收益为 45.66%，净夏普比率达到 1.50。在小微盘占比较重的美股全市场上，模型录得 12.96% 的 RankIC，年化多空净收益与夏普比率分别达到 68.20% 和 1.24，相比传统 Fama-MacBeth 线性回归的 7.61% 和 1.11 有进一步提升。

更值得关注的是其在尾部风险上的防御表现。在美股全市场的小微盘多空对冲协议下，空头端经常因个股突发利好而遭遇向上跳空的逼空行情。多数基线模型在这一严苛约束下遭受了严重的净值损伤，传统 Fama-MacBeth 组合的最大回撤达到 -57.98%，深度因子模型 FactorVAE 的回撤达到 -66.13%，部分时序 Transformer 甚至跌幅超过 -70%。

而 STOCK-JEPA 将全样本最大回撤有效控制在 -40.12%，成为所有受测方法中回撤最小的模型。

随后的对照消融实验清晰揭示了收益来源。在保持下游多层感知机架构完全相同的条件下，若在输入特征中移除修正向量，A 股与美股的 RankIC 分别下跌 2.02 和 3.67 个百分点；若用相同维度的原始上下文表征替代修正向量，其性能依然显著落后于修正向量。

这一对比证实，将时序信息转化为相对于金融先验的潜空间位移，其信息密度与预测有效性明显优于未经锚定的通用特征表示。

慢变量分离与宏观冲击响应特征

除了回测净值表现，论文通过受控仿真实验与宏观事件分析，进一步验证了表征解耦背后的机制有效性。

在受控仿真实验中，研究团队构建了一个数据生成过程已知的动态因子环境。数据中包含两组正交的状态变量：一组是自相关系数达到 0.99 的慢变量，用以模拟宏观经济与基本面周期等长效稳态因子；另一组是自相关系数为 0.80 的快变量，并引入快慢状态的高阶非线性交互，用以模拟高频市场异动。

研究人员在冻结特征后利用带正则化的线性探针测试各表征对真实状态的还原能力：实验结果体现出明确的分工。普通的端到端深度学习模型和标准无先验 JEPA 模型，在线性探针测试中对慢变量的决定系数全部呈现负值，模型容量被高频的快变量完全占据。而在 STOCK-JEPA 框架下，先验锚点对慢变量的恢复决定系数达到 66.14%，对快变量基本不产生反应；增量修正表征对快变量的恢复率达到 49.25%，对慢变量无显著反应。当将锚点与修正表征拼接输入时，慢变量恢复率保持在 62.22%，快变量恢复率达到 55.24%。

这表明双分支结构确实在无监督条件下实现了信号频段的物理分离，先验锚点锁定了低频宏观趋势，而修正分支则精准承接了高频非线性动态。

在实际市场的突发事件响应中，修正表征同样展现了高度的动态敏感性。

每日修正位移采用全市场个股的截面中位数计算，目的是规避个股停牌或财报异动造成的极端值干扰。在两年的测试序列中，这条曲线在多数时间保持在低位窄幅震荡，但会在特定的外生冲击窗口出现脉冲式抬升，突破全测试期 99 分位数的参考阈值。

具体来看，A 股市场上 2024 年 9 月下旬的宏观逆周期政策发布期，以及 2025 年 4 月外贸关税调整期间，个股修正向量均经历了系统性的方向重塑。美股在面对利率预期剧烈重定价与底层大模型引发的技

术再评估时，同样测得类似的位移跳变。这种跨资产的共性表明，修正网络确实感知到了市场整体运行状态的变化，并对相对静态的先验锚点做出了同步修正。

关于QuantML

QuantML 是链接全球顶尖量化人才的高端社群，我们聚焦于机器学习在量化投资中的最前沿应用。

核心价值：

- **顶级社群：** 社区涵盖头部机构从业者、知名私募创始人、机构量化负责人，基金经理，券商金工分析师、GitHub千星作者及顶会学者构成。
- **专业研究：** 持续分享前沿论文、论文研报复现、模型代码、核心Alpha因子以及QuantML–Qlib框架等。



论文 · 目录

上一篇
AI 因子挖掘，为什么依然跑不赢十年前的Alpha101?

下一篇
做了一个没人用的金融 Agent 之后

作者提示: 个人观点，仅供参考